Clasificación y regresión

Objetivos:

Integrar herramientas y criterios técnicos desarrollados previamente en escenarios reales, con restricciones operativas y metas de desempeño concretas. Identificar y formular problemas de aprendizaje supervisado de forma autónoma, discerniendo entre tareas de clasificación o regresión a partir de la naturaleza de los datos y los objetivos de negocio. Sintetizar *datasets* estructurados a partir de señales de datos crudas, aplicando criterios de ingeniería de características (*feature engineering*) para extraer información relevante. Priorizar la utilidad de la solución por sobre la optimización ciega de métricas, entendiendo que el éxito profesional reside en la respuesta a las necesidades del sistema, organización o usuario final. Desarrollar la capacidad de justificar cada decisión del *pipeline* (desde el preprocesamiento hasta la elección del modelo y las métricas de evaluación) en función del contexto, no solo de los números.

Documentar el proceso con el rigor de un trabajo de ingeniería: qué se analizó, qué se decidió, por qué, qué se observó y qué se recomienda, transformando la experimentación en un informe técnico autocontenido que ofrezca conclusiones accionables para terceros, es decir, alguien que lea el informe sin conocer los datos, debería poder entender el problema, el enfoque adoptado y la recomendación final.

Recomendaciones para la resolución del trabajo:

Leer y comprender el contexto de cada experiencia antes de abrir el *dataset*. El contexto es el que define qué es un error costoso, qué métricas son prioritarias y qué restricciones operativas existen. Un *pipeline* construido ignorando el dominio del problema puede ser técnicamente impecable o dar respuestas técnicamente correctas (en el mejor de los casos), pero ser profesionalmente inútil.

No existe una secuencia de pasos predefinida. La guía de laboratorio no indica qué modelos probar, qué preprocesamiento aplicar ni cuántos experimentos realizar. Esas decisiones son parte del ejercicio y deben surgir del análisis del contexto y objetivo de cada problema. Por lo tanto, se espera que cada decisión esté argumentada y que tanto el informe como el código evidencien un proceso de razonamiento genuino, no una ejecución mecánica.

Producción esperada para acreditar la actividad:

La entrega consiste en un informe técnico (formato PDF) y los archivos de código fuente utilizados en la tarea designada en el aula virtual de la asignatura, incluyendo el contenido solicitado en cada punto de la guía. Debe realizarse en tiempo y forma, dentro del plazo establecido en la tarea.

Escribir el informe pensando en un colega profesional o supervisor que no tiene acceso a sus códigos. Si el lector necesita abrir el archivo del código fuente para entender qué hicieron o por qué recomiendan determinado modelo, se considera que el informe ha fallado. El documento debe ser autocontenido, narrativo y visual, evitando pegar fragmentos de código y priorizando la interpretación de resultados. Priorizar la calidad por sobre la cantidad, cuidando la prolijidad general en la confección, incluyendo una portada debidamente identificatoria del trabajo.

Los archivos de código se presentan exclusivamente como evidencia técnica y respaldo de reproducibilidad. Su propósito es permitir la auditoría de los procesos y garantizar que los resultados y conclusiones plasmados en el informe sean replicables de forma exacta. Los resultados presentados en el informe deben ser idénticos a los obtenidos mediante la ejecución de los códigos adjuntos.

Consignas:

Experiencia 1 – Sistema de alerta temprana para ACV en atención primaria

Una red de centros de atención primaria de la salud en una provincia con alta dispersión geográfica enfrenta un problema crítico: los pacientes de zonas rurales suelen llegar a la guardia hospitalaria cuando un ACV (accidente cerebrovascular) ya ocurrió, con la ventana terapéutica cerrada. El tiempo es el factor determinante en el daño neurológico irreversible.

El equipo médico propone implementar un sistema de *screening* automatizado que opere durante la consulta de control periódico: el médico de cabecera registra los datos habituales del paciente y el sistema emite una alerta si el perfil del paciente se corresponde con alto riesgo de ACV. La alerta no reemplaza el criterio médico (al menos por ahora, en la fase de pruebas), sería más bien una señal de que el paciente debería derivarse para evaluación especializada.

Se tiene un *dataset* [1] con información relacionada a un conjunto de pacientes, en donde, se reúnen características que se creen son relevantes para la predicción de los ACV.

Los datos se encuentran tabulados en el archivo "datos_acv.*csv*", se disponen de más de 5100 observaciones. El *dataset* presenta la siguiente estructura:

- *id*: identificador único del paciente.
- *género*: categórica. "hombre", "mujer" u "otro".
- *edad*: numérica, edad del paciente en años.
- *hipertensión*: categórica. "0" no tiene hipertensión, "1" si tiene hipertensión.
- *enfermedad_corazón*: categórica. "0" no tiene ninguna enfermedad del corazón, "1" si tiene al menos una.
- *casado_alguna_vez*: categórica. "0" nunca estuvo ni está casado, "1" estuvo o está casado.
- *tipo_trabajo*: categórica. Se incluyen 5 diferentes, son descriptivas de por sí.
- *tipo_residencia*: categórica. "urbano" y "rural".
- *nivel_glucosa*: numérica, nivel promedio de glucosa en sangre.
- *imc*: numérica, índice de masa corporal.
- *estado_fumador*: categórica. Se incluyen 4, "fumaba", "fuma", "nunca", "desconocido". La categoría "desconocido" se utilizó para completar la información no disponible para esos pacientes.
- *apoplejía*: categórica. "1" si tuvo un ACV, "0" para el caso contrario.

El director médico de la red no tiene formación en Machine Learning. Antes de aprobar la implementación, necesita respuestas concretas. A fines de estar preparados para la junta, detallar y fundamentar cada aspecto de la solución propuesta, respondiendo como mínimo las siguientes premisas:

- ¿Qué significa en términos prácticos que el modelo "falle"? ¿Cuál de los dos tipos de error (falsa alarma o caso no detectado) es más grave en este contexto rural, y cómo se refleja esa prioridad en las decisiones de modelado? ¿Qué métricas priorizaron y por qué?
- ¿Hay alguna variable que, aunque tenga correlación estadística, les genere dudas éticas o clínicas al momento de incluirla en modelo médico?
- La proporción de pacientes que efectivamente sufrieron un ACV en el *dataset* es muy baja. ¿Qué implica eso para la evaluación del modelo? ¿Qué dirían de un modelo que reporta un *accuracy* del 95%?
- El médico de cabecera tiene entre 8 y 12 minutos por consulta. ¿Qué variables del *dataset* pueden relevarse en ese tiempo y cuáles requieren estudios adicionales? ¿Cambia eso la selección de *features* del modelo?

- ¿Qué nivel de confianza tiene el modelo para tomar decisiones clínicas? ¿Existe algún grupo de pacientes (por edad, tipo de trabajo o residencia) para el cual el modelo es claramente menos confiable? ¿Qué instrucciones específicas le darían al médico que usa su sistema cuando le toque atender a una persona de ese perfil?
- Si atendieran a 100 personas hoy, ¿a cuántas con riesgo real estiman que su modelo estaría ignorando? ¿cuántas consultas y estudios médicos ahorrarían? ¿son esas cifras éticamente aceptables para presentarlas al director médico?
- ¿Qué implicancias éticas y prácticas tiene la estrategia elegida para tratar los datos faltantes? ¿Podría la forma de completar los datos introducir un sesgo que perjudique a un grupo de pacientes específico?
- ¿Recomendaría implementar este sistema en la red provincial? En caso afirmativo, ¿Con qué condiciones o restricciones? ¿bajo qué protocolos de seguridad? ¿es viable utilizar el modelo para reemplazar el criterio de un médico y automatizar completamente el proceso de diagnóstico de ACV con este sistema?

Experiencia 2 – Monitor de calidad de aire en espacios de trabajo

Una empresa consultora en salud ocupacional está desarrollando un dispositivo IoT de bajo costo para monitorear la calidad del aire en espacios de trabajo cerrados: cocinas industriales, laboratorios, depósitos con productos de limpieza y oficinas. El dispositivo incluye una matriz de seis sensores de gas y debe clasificar de forma autónoma la situación del ambiente para activar alertas o sistemas de ventilación forzada.

El producto debe funcionar en tiempo real con hardware embebido de recursos limitados (microcontrolador con memoria RAM de 256 KB y capacidad de cómputo equivalente a un Raspberry Pi Pico). El costo de manufactura máximo por unidad es de $18 USD y el precio de venta objetivo es de $35 USD (el margen no permite sensores de mayor precisión ni hardware más potente).

El *dataset* [2] disponible contiene 1.845 muestras de lecturas de los seis sensores etiquetadas con la actividad que las generó: aire limpio, cocción de alimentos, presencia de humo o uso de productos de limpieza.

El conjunto de sensores utilizados se puede agrupar en dos categorías principales:

- Sensores MQ (MQ2, MQ9, MQ135, MQ137, MQ138) que tienen gran sensibilidad, baja latencia y bajo costo; cada sensor puede responder a diferentes gases;
- Sensor analógico de gas CO2 (MG-811) que tiene una excelente sensibilidad al dióxido de carbono y apenas se ve afectado por la temperatura y la humedad del aire.

El equipo encargado de obtener las muestras detalla lo siguiente respecto a la conformación de estas:

1. **Situación normal** - Actividad: aire limpio, una persona que duerme, estudia o descansa. Muestras disponibles: 595.
2. **Preparación de comidas** - Actividades: cocinar carne o pasta, verduras fritas. Una o dos personas en la habitación, circulación de aire forzado. Muestras disponibles: 515.
3. **Presencia de humo** - Actividad: quemar papel y madera por un corto período de tiempo en una habitación con ventanas y puertas cerradas – Muestras disponibles: 195.
4. **Limpieza** - Actividad: uso de detergentes en aerosol y líquidos con amoníaco y/o alcohol. La circulación de aire forzado se puede activar o desactivar - Muestras disponibles: 540.

Cada muestra está compuesta por 7 valores; los primeros seis valores son las salidas de los sensores, mientras que el último es el índice de la acción que generó los valores adquiridos por los mismos. Las cuatro situaciones diferentes están asociadas con una composición del aire distinta, teniendo en cuenta que cualquier actividad produce sustancias químicas (respiración humana, exhalaciones de procesos metabólicos, liberación de volátiles por combustión y/o oxidación, evaporación de detergentes domésticos, etc.).

Los datos se encuentran en el archivo adjunto denominado "*datos_adl.csv*". A continuación, se presenta una porción de este *dataset*:

Tabla 1 — Fragmento del dataset: calidad del aire.

MQ2	MQ9	MQ135	MQ137	MQ138	MG-811	Situación
670	696	1252	1720	1321	2431	4
641	674	1156	1652	1410	2433	1
642	646	1159	1643	1455	2361	3
640	590	1105	1608	1459	2427	4
616	627	1192	1637	1466	2447	2
…	…	…	…	…	…	…

En la columna "*Situación*" se encuentra codificada la clase que indica si se trata de una **actividad normal** (**1**), **preparación de comidas** (**2**), **presencia de humo** (**3**) o de **limpieza** (**4**).

El director de producto necesita una recomendación técnica que contemple no solo la precisión del modelo sino su viabilidad en el hardware objetivo. Por lo tanto, es necesario detallar y fundamentar cada aspecto de la solución propuesta, incluyendo lo que crea conveniente y respondiendo como mínimo las siguientes premisas:

- ¿Qué modelo se ajusta mejor a la solución buscada? ¿Por qué?
- Dado el hardware disponible, ¿qué tipo de modelo es viable y cuáles quedan descartados por restricciones de tiempo de inferencia o memoria? ¿Cómo demostrarían empíricamente ese límite?
- El *dataset* tiene un marcado desbalance entre situaciones: hay casi tres veces más muestras de "aire limpio" que de "presencia de humo". ¿Cómo afecta eso al comportamiento del modelo y qué decisiones toman al respecto? ¿Es necesario pedir más muestras al equipo encargado?
- No todos los errores tienen el mismo nivel de riesgo: una alarma no activada ante presencia de humo es mucho más grave que ante uso de detergentes. ¿Cómo se refleja esa asimetría en el ajuste y/o la evaluación del modelo para minimizar los riesgos fatales?
- Investigar precios al por mayor de sensores MQ vs. MG-811 (incluir en el informe las referencias correspondientes), ¿cuántos y cuáles recomendarían incluir en la versión final del producto para mantener el margen de ganancia sin desmejorar significativamente el desempeño del modelo?
- ¿El modelo desarrollado es robusto ante variaciones de condiciones no vistas durante el entrenamiento (por ejemplo, una cocina con características de humedad y temperatura distintas a las del *dataset*)? ¿Qué limitaciones tiene para uso en producción?
- ¿Qué proponen para la *versión 1.0* del producto (que debe salir rápido al mercado)? ¿Y qué investigación o mejoras sugieren para la *v2.0*?

Experiencia 3 – Optimización de mezclas de hormigón para obra civil

La resistencia a la compresión simple es la característica mecánica principal del concreto. Se define como la capacidad para soportar una carga por unidad de área, y se expresa en términos de esfuerzo [*MPa*]. El cemento es el material más activo de la mezcla de concreto, por tanto, sus características y sobre todo su contenido (proporción) dentro de la mezcla tienen una gran influencia en la resistencia del concreto, a cualquier edad. A mayor contenido de cemento se puede obtener una mayor resistencia y a menor contenido, la resistencia del concreto va a ser menor. Además, existen varios "agregados" que afectan de manera no lineal las proporciones de los materiales para una resistencia determinada.

Una empresa constructora que opera en proyectos de infraestructura vial y edilicia busca reducir el costo de sus mezclas de hormigón sin comprometer los requisitos mínimos de resistencia especificados en cada proyecto. El cemento es el componente más caro y con mayor huella de carbono de la mezcla; cualquier reducción en su proporción, si se compensa con agregados alternativos, representa un ahorro significativo tanto económico como ambiental.

El equipo de ingeniería propone construir un modelo predictivo que, dada una "receta" de hormigón (proporciones de cada componente y edad de curado), estime la resistencia a compresión resultante en MPa. Si el modelo es suficientemente preciso, podría usarse para explorar el espacio de recetas posibles y encontrar formulaciones de menor costo que cumplan los requisitos de cada obra.

El *dataset* [3] disponible contiene 1.030 muestras de mezclas de hormigón con sus componentes y la resistencia medida en laboratorio. La información de estas variables, su tipo y unidades, se especifican de la siguiente manera:

- ***Cement*** *(component 1) -- quantitative -- kg in a m3 mixture -- Input Variable*
- ***Blast Furnace Slag*** *(component 2) -- quantitative -- kg in a m3 mixture -- Input Variable*
- ***Fly Ash*** *(component 3) -- quantitative -- kg in a m3 mixture -- Input Variable*
- ***Water*** *(component 4) -- quantitative -- kg in a m3 mixture -- Input Variable*
- ***Superplasticizer*** *(component 5) -- quantitative -- kg in a m3 mixture -- Input Variable*
- ***Coarse Aggregate*** *(component 6) -- quantitative -- kg in a m3 mixture -- Input Variable*
- ***Fine Aggregate*** *(component 7) -- quantitative -- kg in a m3 mixture -- Input Variable*
- ***Age*** *-- quantitative -- Day (1~365) -- Input Variable*
- ***Concrete compressive strength*** *-- quantitative -- MPa -- Output Variable*

Los datos se encuentran en el archivo adjunto denominado "*datos_ccs.csv*". A continuación, se presenta una porción de este *dataset*:

Tabla 2 — Fragmento del dataset: resistencia del concreto.

cement	slag	flyash	water	superplasticizer	coarseaggregate	fineaggregate	age	csMPa
540.0	0.0	0.0	162.0	2.5	1040.0	676.0	28	79.99
540.0	0.0	0.0	162.0	2.5	1055.0	676.0	28	61.89
332.5	142.5	0.0	228.0	0.0	932.0	594.0	270	40.27
332.5	142.5	0.0	228.0	0.0	932.0	594.0	365	41.05
198.6	132.4	0.0	192.0	0.0	978.4	825.5	360	44.30
…	…	…	…	…	…	…	…	…

En la columna "*csMPA*" se encuentran los valores numéricos correspondientes a la resistencia a la compresión del hormigón, obtenida para la combinación de los demás materiales en las cantidades indicadas en la fila correspondiente.

El jefe de obra es "medio terco", exige fundamentos sólidos y no validará un modelo que no pueda ser explicado. Tampoco aceptará recomendaciones de recetas no tradicionales que el modelo no pueda respaldar cuantitativamente. Por lo tanto, detallar y fundamentar cada aspecto de la solución propuesta, incluyendo los aspectos que crea conveniente y respondiendo como mínimo las siguientes premisas:

- ¿Con qué nivel de precisión puede el modelo predecir la resistencia de una receta nueva? ¿Esa precisión es suficiente para tomar decisiones de obra, donde subestimar la resistencia es un costo extra innecesario y sobreestimar la resistencia es un error estructural fatal?
- ¿Hacia dónde tiende a equivocarse su modelo? ¿Tiende a ser "optimista" (sobreestima) o "pesimista" (subestima)? ¿Cómo ajustarían un "margen de seguridad" sobre la predicción para que el jefe de obra duerma tranquilo?
- ¿Qué componentes tienen mayor influencia sobre la resistencia? ¿Coincide eso con el conocimiento previo de los especialistas en hormigón?
- Los expertos mencionan que hay relaciones no lineales en la composición. ¿Cómo se manifiesta eso en la comparación empírica entre modelos lineales y no lineales? ¿Qué diferencia de desempeño se obtiene?
- ¿Existe algún rango de valores de los componentes o de la edad de curado para el cual el modelo es menos confiable? ¿Qué implicaría usar el modelo fuera de ese rango?
- ¿El preprocesamiento afecta el desempeño? ¿Hay algún componente con distribución o escala que requiera tratamiento especial?
- Si el ingeniero de obra propone una receta experimental que no se parece a ninguna del *dataset* de entrenamiento, ¿confiarían en la predicción del modelo? ¿cómo lo comunicarían?
- El *dataset* provee valores continuos de MPa. Sin embargo, las normas de construcción suelen trabajar con niveles discretos o clases de resistencia (H-20, H-25, H-30, etc.) que se alcanzan a los 28 días. ¿Es posible usar su modelo para asegurar, a los 7 días de curado, por ejemplo, que una mezcla alcanzará su clase objetivo a los 28 días? ¿Cómo plantearían este experimento?

Experiencia 4 – Sistema de control de acceso autónomo en espacios comerciales

Una empresa integradora de sistemas de seguridad está desarrollando un módulo de control de acceso basado en visión por computadora para instalaciones comerciales: shoppings, supermercados y parques de entretenimiento. Una de las funcionalidades requeridas es que las puertas de salida al exterior no se abran automáticamente ante la presencia de menores de edad no acompañados (como medida de seguridad ante extravíos y situaciones de riesgo).

El sistema de visión ya extrae automáticamente medidas corporales del contorno detectado (altura, proporciones de brazos, piernas, cabeza, etc.) sin necesidad de identificación facial ni datos biométricos sensibles. Con esas medidas como *input*, el módulo de clasificación debe determinar si la persona detectada es un niño o un adulto, y actuar en consecuencia.

El umbral etario exacto para la distinción niño/adulto no está fijo: el cliente (responsable de seguridad) puede configurarlo desde un panel de control según su política interna (algunos quieren restringir salidas de menores de 12 años, otros de 14). El sistema debe ser adaptable.

El *dataset* [4] disponible (archivo "*datos_bmd.csv*") contiene medidas corporales de individuos de distintas edades y géneros. La información de estas variables, su tipo y unidades, se especifican de la siguiente manera:

- Género: Masculino y Femenino (M=1 y F=2)
- Edad (1 año en adelante)
- Circunferencia de la cabeza (en centímetros)
- Ancho del hombro (en centímetros)
- Ancho del pecho (en centímetros)
- Abdomen (en centímetros)
- Cintura (en centímetros)
- Caderas (en centímetros)
- Longitud del brazo (en centímetros)
- Hombro a la cintura (en centímetros)
- Cintura a la rodilla (en centímetros)
- Longitud de la pierna (en centímetros)
- Altura total: de la cabeza a los pies (en centímetros)

El responsable de seguridad no aceptará un sistema que ponga en riesgo la seguridad de un menor ni uno que genere falsas alarmas constantes molestando a los clientes adultos y paralizando la operación. Por lo tanto, es necesario argumentar y demostrar cada aspecto de la solución propuesta y su viabilidad, incluyendo lo que crea conveniente y respondiendo como mínimo las siguientes premisas:

- ¿Qué tipo de problema es este realmente? ¿Qué enfoque técnico ofrece mayor flexibilidad operativa dado que el umbral etario es configurable?
- Las medidas absolutas (como la altura) pueden variar mucho entre individuos de una misma edad, ¿el uso de proporciones o ratios corporales (ej. *circunferencia_cabeza* / *altura_total*) aportaría más robustez al modelo que las medidas crudas? Comprueben su hipótesis empíricamente.
- ¿El *dataset* disponible es representativo de la población que el sistema encontrará en producción? ¿Existen rangos etarios o perfiles corporales para los que el modelo es menos confiable?
- ¿Cuál es el error más costoso en este contexto (falso positivo o falso negativo) y cómo se gestiona esa asimetría en el diseño del sistema?
- El sistema opera en tiempo real con una cámara a 30 FPS. ¿Qué consideraciones de latencia y robustez son relevantes para la elección del modelo?
- ¿Existe algún rango de edad para el cual el modelo no debería usarse sin supervisión adicional? ¿Cómo le comunicarían al cliente este "margen de duda"?
- Basándose en la representatividad del *dataset*, ¿recomendarían desplegar este sistema en producción? ¿qué mecanismos de "intervención humana" o salvaguardas legales sugerirían al *shopping* para los casos de error?

Experiencia 5 – Sistema de monitoreo de biodiversidad en reservas naturales

La Administración de Parques Nacionales, en colaboración con una universidad regional, está desarrollando un sistema de monitoreo pasivo de fauna en reservas de la región de Misiones. El monitoreo tradicional requiere presencia humana permanente (costoso, invasivo para la fauna y logísticamente complejo en zonas de difícil acceso). La alternativa es desplegar grabadores de audio autónomos que operen durante semanas y luego procesar los registros automáticamente.

El objetivo es identificar de forma automática la presencia de especies o grupos de interés en los registros de audio. Las "firmas" acústicas de interés incluyen especies de fauna nativa cuya presencia o ausencia

es indicador del estado de salud del ecosistema. El sistema debe poder procesar horas de audio y producir un *log* con estampas de tiempo de detección (herramienta de trabajo real para biólogos y guardaparques).

Se busca un primer prototipo viable, en donde es suficiente con extraer las características de al menos 3 de los principales eventos registrados en el audio (*Audio_clasificar.wav)*, para ajustar un modelo que permita identificarlos correctamente en otros contextos (*ambiente_largo.mp3*). Las firmas espectrales más relevantes son:

- Langosta de alta frecuencia (en torno a los $8{\sim}9\ kHz$)
- Grillos de alta frecuencia (en torno a los $5\ kHz$)
- Chicharra (en torno a los $2\ kHz$)
- Añapero Castaño (*Lurocalis semitorquatus*)
- Yeruvá (*Baryphthengus ruficapillus*)

NOTA: Tener en cuenta que cuanto más simples y relevantes sean las firmas de los eventos ante mencionados, el clasificador funcionará más eficientemente (precisión y consumo de recursos).

Los biólogos que usarán el sistema no son ingenieros. Necesitan entender qué puede hacer el sistema, qué no puede hacer, y cuándo confiar en sus resultados. Detallar y fundamentar cada aspecto de la solución propuesta, incluyendo lo que crea conveniente y respondiendo como mínimo las siguientes premisas:

- Antes de comenzar el procesamiento, analice las propiedades técnicas de los archivos de audio provistos, ¿garantiza la configuración digital del registro la integridad de la información para todas las especies de la lista? ¿Cuál es el límite teórico de frecuencia de su sistema de análisis? ¿Qué fenómeno ocurriría si intentaran detectar un sonido que supere dicho umbral?
- Describa el procedimiento de análisis espectral que le permitiría obtener la firma de cada evento. ¿Cómo transformaron un archivo de varios segundos en un conjunto de muestras para entrenamiento? ¿Qué criterios utilizaron para decidir dónde comienza y dónde termina un evento?
- ¿Cómo se extrae una "firma" acústica útil de una señal de audio cruda? ¿Por qué trabajar en el dominio de la frecuencia en lugar del tiempo para este tipo de problema?
- Si tuvieran que describirle a un biólogo qué es lo que el modelo “escucha” para distinguir una especie de otra, ¿qué características matemáticas o visuales resultaron ser las más discriminatorias? ¿Por qué la simple amplitud de la señal no es un rasgo confiable en este entorno?
- ¿Es posible reducir la dimensionalidad de las firmas espectrales sin perder la información necesaria para distinguir las especies? ¿Qué ventajas operativas tiene esa reducción en un sistema embebido desplegado en campo?
- ¿Qué sucede cuando en el audio coinciden simultáneamente dos o más eventos? ¿El sistema puede gestionar esa situación o tiene limitaciones conocidas? ¿Cómo debería adaptarse el diseño para registrar múltiples especies en un mismo instante de tiempo?
- ¿Qué ocurre cuando el sistema encuentra un sonido que no corresponde a ninguna de las clases entrenadas? (por ejemplo, una especie no incluida o ruido de lluvia intensa) ¿Cómo se comporta su modelo actual y cómo debería comportarse idealmente en un despliegue profesional? ¿Qué estrategias de diseño proponen para gestionar estos eventos desconocidos?
- Al validar el sistema sobre *ambiente_largo.mp3*, ¿el desempeño en condiciones reales es coherente con el desempeño en el audio de entrenamiento? ¿Qué diferencias observan y a qué las atribuyen?
- El sistema debe correr en un grabador autónomo con batería y almacenamiento limitados. ¿El *pipeline* completo (extracción de características, clasificación, generación de *log*) es viable en ese hardware? Si el grabador debe operar seis meses en el monte con una batería pequeña, ¿Qué

simplificaciones o compromisos harían primero para estirar la autonomía sin que el sistema deje de ser útil para el guardaparque?

- ¿El sistema entrega un *log* de detecciones confiable o requiere demasiada supervisión humana? ¿Qué mejoras son prioritarias antes de instalar 50 de estos dispositivos en medio de la selva?

Referencias:

[1] McKinsey Analytics Online Hackathon, «Conjunto de datos refinados del Registro Electrónico de Salud (EHR), sólo fines académicos,» *Healthcare Analytics,* 2018.

[2] E. Gambi, «Air Quality dataset for ADL classification,» *Mendeley Data, V1, doi: 10.17632/kn3x9rz3kd.1,* 2020.

[3] I.-C. Yeh, «Concrete Compressive Strength,» *UCI Machine Learning Repository, doi: 10.24432/C5PK67,* 2007.

[4] M. Kiru, «Body Measurements Datasets,» *Mendeley Data, V1, doi: 10.17632/bjv6c9pmp4.1,* 2021.

Anexos:

Saberes vinculados a la actividad:

Saberes conocer	Saberes hacer	Saberes ser
Inteligencia Computacional (intra cátedra): - EDA - Conceptos de variable *target*, *features* - *Data shapes* - Modelos de aprendizaje supervisado lineales y no lineales - Métricas de desempeño - Ingeniería de características Estadística (conceptos previos): - Distribuciones de probabilidad - Uso de matrices de correlación y diagramas de dispersión para el análisis multivariado - Incertidumbre - Ajuste de curva - Análisis de residuos - Intervalos de confianza - Sesgo y varianza Programación (conceptos previos): - POO - Prácticas de reproducibilidad Señales: - Dominio del tiempo vs. dominio de la frecuencia (FFT) - Digitalización de señales analógicas - Teorema de muestreo Otros conocimientos transversales: - Implicancias éticas y legales de la automatización y gestión del riesgo en sistemas críticos	Inteligencia Computacional (intra cátedra): - Identificar y tratar anomalías en los datos (nulos y *outliers*) con criterio técnico - Formular hipótesis basadas en evidencia estadística y visual para guiar el preprocesamiento - Seleccionar variables basándose en el costo de adquisición del dato y la capacidad de cómputo del hardware objetivo - Discernir y justificar la elección entre clasificación y regresión según el objetivo - Interpretar métricas y validar resultados mediante contraste de gráficos y negocio - Cuantificar el impacto económico o humano de los tipos de errores Otras habilidades transversales: - Documentar y comunicar hallazgos técnicos de forma clara - Traducir métricas matemáticas en recomendaciones accionables - Justificar la toma de decisiones ante problemas con o sin contexto previo	- Autosuficiencia y proactividad - Razonamiento basado en sentido común para la interpretación de resultados - Capacidad de abstracción e inferencia lógica - Escepticismo profesional para cuestionar los datos y resultados - Rigurosidad y prolijidad en la entrega de trabajos reproducibles, organizados y legibles para pares - Responsabilidad civil y ética en el desarrollo de sistemas críticos - Pensamiento sistémico para la integración de soluciones tecnológicas - Integridad técnica en la comunicación de limitaciones y fallas de los modelos